

Análisis del Trade-off entre Precisión y Desinformación en Sistemas de Recomendación de Noticias basados en Grafos

⚠️ ¿Estamos optimizando la viralización de mentiras? Una evaluación de GNNs y Modelos Clásicos.

Vittorio Salvatore, Clemente Acevedo, Cristóbal Fuentes
Pontificia Universidad Católica de Chile · IIC3633 - Sistemas Recomendadores

1. Motivación: El Desafío de la Desinformación

Las redes sociales han democratizado el acceso a la información, pero también han facilitado la propagación viral de noticias falsas. Los algoritmos de recomendación, al optimizar ciegamente la interacción del usuario, pueden amplificar este contenido nocivo.

📈 Viralidad Diferencial

Las fake news generan

1.8x

más interacciones que noticias verdaderas
(33.0 vs 18.1 promedio)




Figura: Viralidad Orgánica: Análisis de datasets *Twitter15* y *Twitter16*. Los algoritmos corren el riesgo de aprender y exacerbar este sesgo.

? Pregunta de Investigación

¿Son los modelos de última generación, como las *Graph Neural Networks* (GNNs), capaces de mitigar este fenómeno, o lo empeoran en su búsqueda de mayor precisión?

Dataset: Twitter15 y Twitter16

Utilizamos los datasets **Twitter15** y **Twitter16**, benchmarks clásicos para estudiar *rumor detection* y difusión de noticias. Cada conjunto está centrado en **eventos/rumores** asociados a un **tweet raíz**, junto con su **cascada de propagación** (respuestas/retweets) y señales sociales (usuarios e interacciones).

Las noticias se anotan como **True Rumor (TR)**, **False Rumor (FR)** y **Unverified (UR)**, permitiendo cuantificar exposición a desinformación.

2. Metodología

39,958 Usuarios
110,732 Interacciones

Aplicamos un split temporal estricto (80/10/10) para simular un escenario de recomendación realista sin filtración de datos futuros.

🔗 Grafo Social Implícito y Thresholding

Para modelar la difusión, construimos un grafo conectando usuarios con intereses similares. Establecimos un umbral de ≥ 3 ítems compartidos basándonos en la evidencia estadística:




Figura: El **98.9 %** de los pares no comparten ítems. Un umbral de 3 filtra el ruido de coincidencias aleatorias, reteniendo solo conexiones significativas.

Visualización del Grafo Social Generado




Figura: Visualización del Grado Social generato. Se observa la presencia de nodos hubs y clusters distintos.

📊 Nueva Métrica: Fake@K

Para cuantificar el riesgo de manera objetiva, formalizamos la métrica:

$$\text{Fake@K} = \frac{1}{|U|} \sum_{u \in U} \frac{|\{i \in \text{Top-}K_u : \text{label}(i) = \text{FR}\}|}{K}$$

Mide la proporción de *False Rumors* (FR) que el modelo inyecta en las listas de recomendación.

3. Resultados: El Trade-off

Evaluamos 8 modelos distintos. Al cruzar la precisión (MRR) con la seguridad (Fake@K), emerge una clara **Frontera de Pareto**:




Figura: Precisión vs. Seguridad. Se observa que mayor precisión conlleva mayor riesgo. LightGCN domina en precisión pero falla en seguridad.

⚠️ HALLAZGO CRÍTICO

LightGCN amplifica la desinformación en un **+10 %** respecto al sesgo orgánico del dataset, exponiendo a los usuarios a un **67.5 %** de fake news.

- ⬆️ **Alta Precisión, Alto Riesgo:** LightGCN obtiene el mejor MRR (0.0347) pero expone al usuario a un **67.5 % de Fake News**.
- 🌿 **Seguridad Semántica:** GCN-BERT sacrifica precisión (MRR 0.0153) pero es el único modelo que **reduce** la desinformación (50.5 %) gracias a embeddings de texto.




Figura: Los modelos híbridos logran diversificar hacia contenido '**Verdadero**', mientras que TF-IDF satura con '**Falso**'.

4. Impacto Social y Conclusiones

Simulamos el impacto social utilizando el **Linear Threshold Model (LTM)**. Los resultados confirman que la diversidad en las recomendaciones actúa como un cortafuegos: los modelos más diversos (como GCN-BERT) generaron cascadas de difusión más pequeñas y lentas.

Conclusiones Principales:

✓ 1. Trade-off Confirmado

Existe una tensión inherente e inevitable entre maximizar la precisión (MRR) y minimizar la exposición a desinformación con las arquitecturas actuales.

! 2. La Complejidad no garantiza Seguridad

Modelos estructurales simples como **ItemKNN** resultaron ofrecer un mejor balance ético que GNNs complejas que no incorporan semántica.

👉 3. Recomendación

Para entornos sensibles (noticias, salud), se debe priorizar modelos en la “zona balanceada” de la frontera de Pareto o implementar mecanismos de re-ranqueo basados en contenido.

🏆 Modelo Recomendado

ItemKNN + Content Filtering

Balance óptimo entre precisión y seguridad
MRR: 0.0347 · Fake@10: 56.0 %

📁 Repositorio y Código:

github.com/aLotOfGluten/IIC3633-Proyecto